

Ablação da variável `cycle` — RUL FD001

A variável `cycle` foi considerada muito importante pela análise de permutação. Essa importância pode ser legítima, porque o ciclo informa a idade observada do motor, mas também pode fazer o modelo depender demais de um marcador de tempo que não explica sozinho a vida útil de cada trajetória.

Será feita uma ablação: dois pipelines iguais serão comparados, com a mesma configuração do Extra Trees v1, alterando somente a presença da variável `cycle`. Essa é uma comparação controlada, e a validação continuará sendo feita por motor.

```
In [1]: from pathlib import Path
import sys
import pandas as pd
import plotly.express as px
import plotly.io as pio
from IPython.display import HTML, display
from multilang import LangMap

pio.renderers.default = 'vscode'
lang = LangMap(source='pt', target='pt')

PROJECT_ROOT = Path.cwd().resolve()
if not (PROJECT_ROOT / 'data' / 'raw' / 'dataset').exists():
    PROJECT_ROOT = Path.cwd().resolve().parents[1]
if str(PROJECT_ROOT / 'src') not in sys.path:
    sys.path.insert(0, str(PROJECT_ROOT / 'src'))

from cmapss_eda import load_split
from cmapss_modeling import add_rul_label, candidate_rul_features, nonconstant_features
from cmapss_optuna import build_pipeline_from_params, optimize_model
from cmapss_ablation import evaluate_grouped_model

DATA_DIR = PROJECT_ROOT / 'data' / 'raw' / 'dataset'
```

1. Preparação e configuração congelada

Será usada a mesma base de treino e os mesmos hiperparâmetros do melhor trial do Extra Trees v1. A consulta ao estudo persistido apenas recupera a configuração já escolhida; não será realizada uma nova otimização.

```
In [2]: train = add_rul_label(load_split(DATA_DIR, 'train', 'FD001'))
features_with_cycle = nonconstant_features(
    train,
    candidate_rul_features(include_settings=True),
)
features_without_cycle = [
    feature for feature in features_with_cycle if feature != 'cycle'
]
study = optimize_model(
    train, features=features_with_cycle, model_name='Extra Trees',
    n_trials=100, n_splits=5, random_state=42,
    storage_dir=PROJECT_ROOT / 'outputs' / 'optuna',
    search_version='v1',
)
model_with_cycle = build_pipeline_from_params(
    'Extra Trees', study.best_params, len(features_with_cycle),
    random_state=42, search_version='v1',
)
model_without_cycle = build_pipeline_from_params(
    'Extra Trees', study.best_params, len(features_without_cycle),
    random_state=42, search_version='v1',
)
```

[I 2026-09-28 14:58:01,019] Using an existing study with `study\_name='fd001\_extra\_trees\_v1'` instead of creating a new one.

2. Comparação na validação por motor

A validação será repetida com os mesmos cinco grupos de motores. O resultado sem `cycle` não será otimizado separadamente; essa escolha mantém a comparação como uma ablação do atributo, e não como uma disputa entre duas buscas diferentes.

```
In [3]: summary_with_cycle, predictions_with_cycle = evaluate_grouped_model(
    train, features_with_cycle, model_with_cycle, n_splits=5,
)
summary_without_cycle, predictions_without_cycle = evaluate_grouped_model(
    train, features_without_cycle, model_without_cycle, n_splits=5,
```

```
)
comparison = pd.concat([
    summary_with_cycle.assign(configuracao='Com cycle'),
    summary_without_cycle.assign(configuracao='Sem cycle'),
], ignore_index=True)
comparison[['configuracao', 'mae_medio_motor', 'rmse_medio_motor', 'erro_medio_motor', 'percentual_superestimacao',
```

```
Out[3]:
```

	configuracao	mae_medio_motor	rmse_medio_motor	erro_medio_motor	percentual_superestimacao	percentual_subestimacao
0	Com cycle	25.01	29.10	5.69	59.81	40.19
1	Sem cycle	28.92	36.74	4.36	57.34	42.66



Insights

A comparação mostrará o quanto do desempenho depende da idade observada do motor. Se a remoção de `cycle` aumentar pouco o erro, os sensores carregam informação suficiente para sustentar a previsão. Se o erro aumentar bastante, o modelo depende fortemente do tempo de operação e deverá ser interpretado com mais cautela em conjuntos com vidas úteis diferentes.

```
In [4]: plot_data = comparison.melt(
    id_vars='configuracao',
    value_vars=['mae_medio_motor', 'rmse_medio_motor'],
    var_name='metrica',
    value_name='ciclos',
)
fig = px.bar(
    plot_data,
    x='metrica',
    y='ciclos',
    color='configuracao',
    barmode='group',
    labels={'metrica': 'Métrica', 'ciclos': 'Erro (ciclos)', 'configuracao': 'Configuração'},
    title=lang({'title': 'Efeito da remoção de cycle nas métricas de validação'})['title'],
    height=550,
)
display(HTML(fig.to_html(full_html=False, include_plotlyjs='inline')))
```

Efeito da remoção de cycle nas métricas de validação



Referências

GEURTS, P.; ERNST, D.; WEHENKEL, L. Extremely randomized trees. Machine Learning, v. 63, p. 3–42, 2006.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.